

BLM0463 VERİ MADENCİLİĞİNE GİRİŞ

DÖNEM PROJESİ RAPORU

**CineScale2 Veri Seti Üzerinde Karar Ağacı ile Kamera Açısı ve Seviyesi
Sınıflandırması**

Ders: BLM0463 – Veri Madenciliğine Giriş

Asım Burak Öztürk

22360859063

Github Linki: <https://github.com/AsmBrk/CineScale2-Filmlerdeki-sinematik-kamera-zelliklerinin-veriseti>

Youtube Linki: <https://youtu.be/1mhEUax6-rl>

1. Giriş

Sinema sanatında kamera açısı ve kamera seviyesi, izleyicinin sahneyi algılama biçimini doğrudan etkileyen temel görsel unsurlardır. Kamera parametrelerinin otomatik olarak tanınması; film analizi, içerik tabanlı video arama ve medya psikolojisi gibi alanlarda büyük önem taşımaktadır.

Bu projede, Data in Brief dergisinde yayımlanan CineScale2 veri seti kullanılarak karar ağacı (Decision Tree) yöntemiyle iki ayrı sınıflandırma modeli geliştirilmiştir. Birinci model kamera açısını (Angle), ikinci model ise kamera seviyesini (Level) tahmin etmektedir. Her iki modelde de görüntü çerçevelerinin ortalama R, G ve B renk kanalı değerleri girdi özelliği olarak kullanılmıştır.

2. Veri Seti: CineScale2

2.1 Genel Bakış

CineScale2, Savardi ve arkadaşları tarafından 2023 yılında Data in Brief dergisinde (Cilt 51, Makale No: 109627) yayımlanmıştır. Veri seti, çeşitli filmlerden ve sinematografi web sitelerinden derlenen yaklaşık 24.748 video çerçevesini kapsamaktadır. Bu çalışmada iki alt veri seti kullanılmıştır: kamera açısı (Angle) ve kamera seviyesi (Level).

2.2 Kamera Açısı (Angle) Sınıfları

Kamera açısı alt veri seti 9.129 çerçeve içermekte olup beş sınıfa ayrılmaktadır:

- Overhead: Kameranın tam yukarıdan aşağıya baktığı çekimler
- High: Kameranın konuya yukarıdan baktığı çekimler
- Neutral: Göz hizasına yakın, standart çekimler
- Low: Kameranın aşağıdan yukarıya baktığı çekimler
- Dutch: Kameranın yatay eksen etrafında eğik tutulduğu çekimler

2.3 Kamera Seviyesi (Level) Sınıfları

Kamera seviyesi alt veri seti 12.495 eğitim çerçevesi içermekte olup altı sınıfa ayrılmaktadır:

- Aerial: Havadan çekim, çok yüksek bakış açısı
- Eye: Göz hizasında çekim
- Ground: Zemin hizasında çekim
- Hip: Kalça hizasında çekim
- Knee: Diz hizasında çekim
- Shoulder: Omuz hizasında çekim


2.4 Kullanılan Özellikler

Şekil 1. Kamera Açısı (Angle) – Karar Ağacı Yapısı

4.2 Performans Metrikleri

Metrik	Değer	Açıklama
Accuracy (Doğruluk)	%55.91	Doğru sınıflandırılan örneklerin oranı
Sensitivity (Duyarlılık)	%22.85	Gerçek pozitifleri yakalama oranı
Specificity (Özgüllük)	%80.91	Gerçek negatifleri doğru tanımlama oranı
F-measure (F1-Skoru)	%20.09	Precision ve Recall'ın harmonik ortalaması

4.3 Karmaşıklık Matrisi



Şekil 2. Kamera Açısı (Angle) – Karmaşıklık Matrisi


4.4 Yorum

Model, tüm sınıfları büyük ölçüde 'high' olarak tahmin etmiştir. Bunun temel nedeni 'high' sınıfının veri setinde en kalabalık sınıf olmasıdır. 'Dutch' ve 'overhead' gibi az örnekli sınıflarda model neredeyse hiç doğru tahmin yapamamıştır. Özgüllüğün yüksek (%80.91), duyarlılığın ise düşük (%22.85) olması modelin pozitif örnekleri büyük ölçüde kaçırdığını ortaya koymaktadır.

5. Model 2 – Kamera Seviyesi (Level) Sınıflandırması

5.1 Karar Ağacı Yapısı

Kök düğüm $G_Ortalama \leq 86.313$ koşulunu test etmektedir. Kamera seviyesi modelinde de yeşil kanal ortalaması en belirleyici özellik olarak öne çıkmaktadır.




Şekil 3. Kamera Seviyesi (Level) – Karar Ağacı Yapısı

5.2 Performans Metrikleri

Metrik	Değer	Açıklama
Accuracy (Doğruluk)	%59.22	Doğru sınıflandırılan örneklerin oranı
Sensitivity (Duyarlılık)	%28.95	Gerçek pozitifleri yakalama oranı
Specificity (Özgüllük)	%90.18	Gerçek negatifleri doğru tanımlama oranı
F-measure (F1-Skoru)	%23.93	Precision ve Recall'ın harmonik ortalaması

5.3 Karmaşıklık Matrisi



Şekil 4. Kamera Seviyesi (Level) – Karmaşıklık Matrisi

5.4 Yorum

Kamera seviyesi modeli, kamera açısı modeline kıyasla tüm metriklerde daha iyi performans sergilemiştir. Bununla birlikte model büyük ölçüde 'aerial' ve 'eye' sınıflarına yönelmiş; 'ground', 'hip', 'knee' ve 'shoulder' sınıflarında tahmin başarısı oldukça düşük kalmıştır. Özgüllüğün yüksek (%90.18) ancak duyarlılığın düşük (%28.95) olması, modelin gerçek pozitif örnekleri yakalamakta güçlük çektiğini göstermektedir. Bu durum yine sınıf dengesizliğinin ve renk tabanlı özelliklerin yetersizliğinin bir yansımasıdır.

6. İki Modelin Karşılaştırılması

Aşağıdaki tablo, kamera açısı ve kamera seviyesi modellerinin performansını yan yana sunmaktadır:

Metrik	Kamera Açısı (Angle)	Kamera Seviyesi (Level)
Accuracy	%55.91	%59.22
Sensitivity	%22.85	%28.95
Specificity	%80.91	%90.18
F1-Skoru	%20.09	%23.93
Sınıf Sayısı	5	6

Kamera seviyesi modeli her metrikte kamera açısı modelini geride bırakmıştır. Bu durum, renk kanallarının kamera açısındaki ince perspektif farklılıklarını ayırt etmekte yetersiz kalırken, kamera yüksekliğine (seviyesine) bağlı renk dağılımlarıyla daha anlamlı bir korelasyon kurabildiğine işaret etmektedir.

7. Literatürle Karşılaştırma

CineScale2 makalesi (Savardi ve ark., 2023), kamera parametrelerinin sınıflandırılması için ResNet mimarisi tabanlı CNN modelleri sunmaktadır. Bu modeller görüntünün tüm piksel bilgisini derin öğrenme katmanlarıyla işleyerek anlamlı görsel özellikler çıkarmaktadır.

Yöntem	Accuracy	Notlar
Karar Ağacı – Açı (Bu Çalışma)	%55.91	3 RGB özelliği, scikit-learn
Karar Ağacı – Seviye (Bu Çalışma)	%59.22	3 RGB özelliği, scikit-learn
CNN (ResNet – Savardi et al., 2023)	~%70+	Derin öğrenme, tam piksel bilgisi

Bu çalışmada uygulanan Karar Ağacı yöntemi yalnızca üç renk özelliği kullandığından CNN'nin zengin görsel örüntü tanıma kapasitesine ulaşmak mümkün olmamıştır. Bununla birlikte karar ağaçları yorumlanabilirlik ve düşük hesaplama maliyeti açısından önemli avantajlar sunmaktadır.

8. Tartışma ve İyileştirme Önerileri

Her iki modelde de elde edilen performans değerleri, kullanılan yüzeysel renk özelliklerinin tek başına yeterli olmadığını ortaya koymaktadır. Performansı artırmak için aşağıdaki adımlar uygulanabilir:

- Özellik Zenginleştirme: Ortalama RGB yerine histogram tabanlı renk dağılımı, kenar yoğunluğu (Sobel/Canny) veya frekans alanı özellikleri (DCT katsayıları) kullanılabilir.
- Sınıf Dengesizliği: SMOTE veya sınıf ağırlıklandırma yöntemleriyle azınlık sınıfları desteklenebilir.
- Topluluk Öğrenmesi: Random Forest veya Gradient Boosting ile tek ağacın aşırı öğrenme eğilimi azaltılabilir.
- Derin Özellikler: Önceden eğitilmiş CNN modellerinden (ResNet, VGG) çıkarılan özellikler karar ağacına girdi olarak verilebilir.

9. Deney Sonuçları ve Genel Değerlendirme

9.1 Özet Tablo

Proje kapsamında yürütülen iki deneyin bulguları aşağıda özetlenmiştir:

Metrik	Angle Modeli	Level Modeli	Yorum
Accuracy	%55.91	%59.22	Level modeli ~3 puan daha iyi
Sensitivity	%22.85	%28.95	Her iki modelde de pozitif örnekler kaçırılıyor

Specificity	%80.91	%90.18	Negatif örnekler büyük ölçüde doğru ayrılıyor
F1-Skoru	%20.09	%23.93	Genel denge her iki modelde de düşük

9.2 Temel Bulgular

- Her iki model de sınıf dengesizliği nedeniyle baskın sınıflara (Angle: 'high', Level: 'aerial') yönelmiştir.
- Kamera seviyesi modeli, renk kanallarıyla daha anlamlı bir ilişki kurabildiğinden kamera açısı modelini tüm metriklerde geçmiştir.
- Yalnızca 3 renk özelliği (R, G, B ortalaması) her iki görsel kavramı tam olarak temsil etmek için yetersiz kalmıştır.
- Karar ağaçları; yorumlanabilirlik, hız ve düşük kaynak kullanımı açısından derin öğrenmeye kıyasla belirgin avantaj sunmaktadır.

9.3 Öğrenilen Dersler

Bu proje; özellik seçiminin model başarısı üzerindeki kritik etkisini, sınıf dengesizliğinin metrikleri yanıltıcı hale getirebildiğini ve basit yorumlanabilir modellerin derin öğrenme ile karşılaştırmalı değerlendirilmesinin önemini somut biçimde ortaya koymuştur.

10. Sonuç

Bu projede CineScale2 veri seti üzerinde iki ayrı karar ağacı modeli geliştirilmiştir. Kamera açısı modeli %55.91, kamera seviyesi modeli ise %59.22 genel doğruluk elde etmiştir. Her iki modelde de ortalama RGB renk kanallarının kamera parametrelerini doğrudan temsil etmekte yetersiz kaldığı görülmüştür.

Bununla birlikte karar ağaçlarının güçlü yorumlanabilirlik özelliği, modelin hangi renk koşullarında hangi kararları aldığını şeffaf biçimde ortaya koymuştur. İlerleyen çalışmalarda daha zengin görsel özellikler ve topluluk öğrenme yöntemleriyle performansın önemli ölçüde artırılacağı öngörülmektedir.

11. Kaynakça

- [1] Savardi, M., Kovács, A. B., Signoroni, A., & Benini, S. (2023). CineScale2: A dataset of cinematic camera features in movies. Data in Brief, 51, 109627. <https://doi.org/10.1016/j.dib.2023.109627>
- [2] Savardi, M., Kovács, A. B., Signoroni, A., & Benini, S. (2021). CineScale: A dataset of cinematic shot scale in movies. Data in Brief, 36, 107002.
- [3] Breiman, L., Friedman, J., Olshen, R., & Stone, C. (1984). Classification and Regression Trees. Wadsworth.
- [4] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

[5] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. IEEE CVPR, 770–778.